

Convolutional Neural Network para diagnóstico de neumonía

Víctor Trigo

18 de enero de 2020

Agenda

- Introducción
- Planteamiento del problema
- Estado del Arte
- Objetivo/Hipótesis
- Materiales
- Resultados
- Conclusiones

Introducción

Neumonía:

- Infección del tejido pulmonar.
- Comúnmente encontrada en niños y adultos mayores a 65 años.
- Su diagnóstico requiere principalmente una radiografía de tórax y examen físico.




Introducción

- Convolutional Neural Network

Es un modelo de redes neuronales artificiales especializado en el análisis de imágenes.

Utiliza operaciones matriciales llamadas Convoluciones.






Planteamiento del problema

Diagnosticar es un proceso de razonamiento que necesita años de estudio y especialización.

Si deseamos mejorar nuestras habilidades de diagnóstico a través de ML, debemos utilizar los métodos apropiados: en este caso Computer Vision.


Estado del Arte

- Coches autónomos
- Reconocimiento de caracteres
- Reconocimiento de Caras



Estado del Arte

- Cáncer de piel, melanoma benigno o maligno
- Clasificación de epilepsia: normales, preictales y convulsivas.
- Diagnostico neumonía
- Diferenciar entre neumonía y COVID-19



Objetivo/Hipótesis

- Construir un modelo de Redes Neuronales Convolucionales que permita predecir la presencia de neumonía en una radiografía de tórax.

Es posible predecir neumonía a través de radiografía de tórax utilizando CNN.

El modelo tiene buenas propiedades de generalización.

Materiales: Datos

<https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia>


- 5.863 imágenes de radiografía de tórax etiquetadas.
- Imágenes reescaladas a 150 x 150 px y un canal de color

Training: 4.707

Validation: 624

Test: 508

Materiales: Técnicas

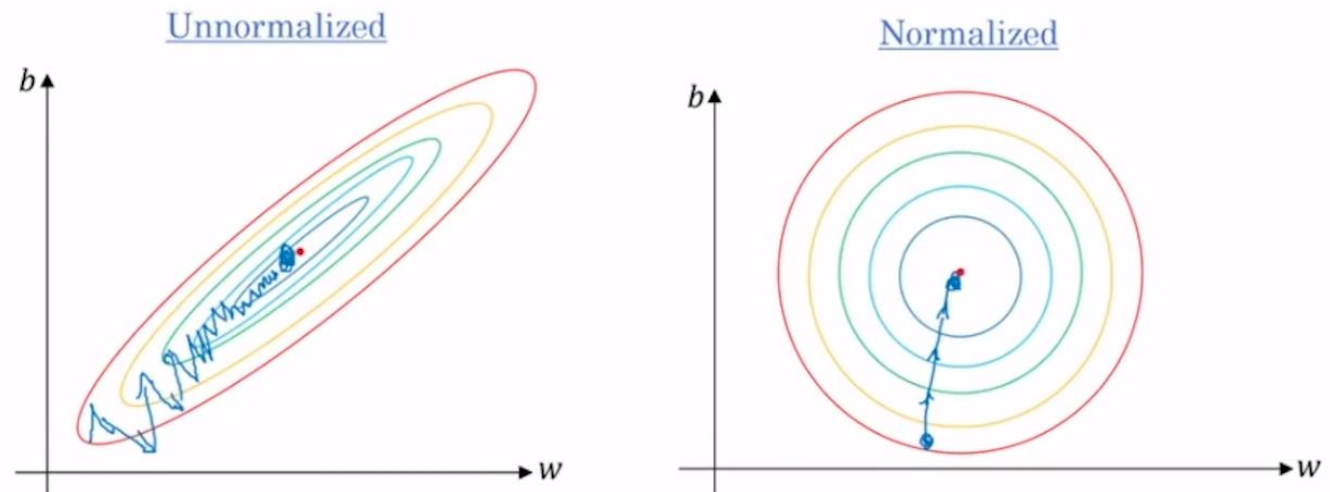


Materiales: Técnicas

- Data Augmentation



- Batch Normalization





Resultados


- Loss 0.4089
- Accuracy 87.34 %

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 75, 75, 32)	320
activation (Activation)	(None, 75, 75, 32)	0
batch_normalization (BatchNo	(None, 75, 75, 32)	128
conv2d_1 (Conv2D)	(None, 75, 75, 64)	18496
activation_1 (Activation)	(None, 75, 75, 64)	0
batch_normalization_1 (Batch	(None, 75, 75, 64)	256
max_pooling2d (MaxPooling2D)	(None, 25, 25, 64)	0
dropout (Dropout)	(None, 25, 25, 64)	0
conv2d_2 (Conv2D)	(None, 25, 25, 96)	55392
activation_2 (Activation)	(None, 25, 25, 96)	0
batch_normalization_2 (Batch	(None, 25, 25, 96)	384
max_pooling2d_1 (MaxPooling2	(None, 6, 6, 96)	0
dropout_1 (Dropout)	(None, 6, 6, 96)	0
flatten (Flatten)	(None, 3456)	0
dense (Dense)	(None, 2)	6914
Total params: 81,890		
Trainable params: 81,506		
Non-trainable params: 384		

Resultados



Resultados



- Accuracy = 0.87
- Recall = 0.95
- Especificidad = 0.73
- Precisión = 0.86
- Valor predictivo negativo = 0.91

Conclusiones

- Construimos una arquitectura neuronal capaz de predecir la presencia de neumonía en radiografías de tórax. El modelo obtuvo un accuracy de 87% como medida de generalización. El modelo es menos fuerte en especificidad con 73% en contraste con recall de 95%.
- El estudio de CNN es complejo, solamente utilizamos las características fundamentales de esta herramienta. Para trabajos futuros se propone no solo mejorar la arquitectura neuronal, sino también utilizar arquitecturas más complejas de CNN (Alexnet, ResNet, LeNet, etc) y el uso de aprendizaje por transferencia.

Referencias

- [1] Kermany, D. S., Goldbaum, M., Cai, W., Valentim, C. C., Liang, H., Baxter, S. L., ... & Zhang, K. (2018). Identifying medical diagnoses and treatable diseases by image-based deep learning. *Cell*, 172(5), 1122-1131.
- [2] Durán Suárez, J. (2017). Redes neuronales convolucionales en R: Re-conocimiento de caracteres escritos a mano.
- [3] Montoya, Ó. P. (2018). Redes Neuronales Convolucionales Profundas para el reconocimiento de emociones en imágenes. Universidad Politécnica de Madrid.
- [4] Pérez Rodríguez, M. (2021). Reconocimiento eficiente de caras mediante Deep Learning a partir de imágenes en el espectro visible.
- [5] Tejada Layme, G. M., & Gonzales Chama, R. P. (2020). Arquitectura de red neuronal convolucional para diagnóstico de cáncer de piel.
- [6] Lopez-Betancur, D., Bosco Duran, R., Guerrero-Mendez, C., Zambrano Rodríguez, R., & Saucedo Anaya, T. (2021). Comparación de arquitecturas de redes neuronales convolucionales para el diagnóstico de COVID-19. *Computación y Sistemas*, 25(3).
- [7] Osada Mochizuki, J. A. (2012). Implementación de un vehículo de pruebas para el desarrollo de un sistema de estacionamiento autónomo mediante visión robótica.
- [8] Acharya, U. R., Oh, S. L., Hagiwara, Y., Tan, J. H., Adeli, H. (2018). Deep convolutional neural network for the automated detection and diagnosis of seizure using EEG signals. *Computers in biology and medicine*, 100, 270-278